Санкт-Петербургский Национальный Исследовательский Университет
Информационных Технологий, Механики и Оптики

Факультет инфокоммуникационных технологий

Домашнее задание №1
Вариант №1

Выполнил:
Бацанова Е. А.
Проверил
Мусаев А.А.

Санкт-Петербург,
2024

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ

Целью данной работы является ознакомление с алгоритмами поиска подстрок, их сравнение, а также применение данных алгоритмов для решения практических задач. Задачами данной лабораторной работы являются:

1) реализация алгоритмов поиска подстрок, а именно наивного алгоритма, алгоритма Рабина-Карпа, Бойера-Мура и Кнута-Морриса-Пратта;
2) сравнение изученных алгоритмов поиска подстрок, выделение их достоинств и недостатков;
3) решение задачи подсчета количества наиболее часто встречающихся двузначных чисел в строке, состоящей из 500 чисел Фибоначчи с использованием каждого из алгоритмов поиска подстрок;
4) решение задачи определения количества плагиата в тексте реферата с помощью одного (оптимального) из реализованных ранее алгоритмов.

Задание 1

Задание: Заполните массив 500 числами (четный вариант – простые числа, нечетный вариант – числа Фибоначчи) написанными слитно. Используя каждый изученный алгоритм поиска подстрок (наивный, Рабина-Карпа, Бойера-Мура, Кнута-Морриса-Пратта), посчитайте количество наиболее часто встречающихся двузначных чисел в образовавшейся строке. Сравните изученные алгоритмы поиска подстрок. Сделайте вывод о их достоинствах и недостатках.

Решение:

Взят вариант 1 – заполняем массив числами Фибоначчи. Создадим строку из чисел Фибоначчи с помощью функции *fibonacci()* (рис. 1).

```
def fibonacci():
    mas = [0, 1, 1]
    while len(mas) <= 500:
        mas.append(mas[len(mas) - 1] + mas[len(mas) - 2])
    return ''.join(map(str, mas))
```

Рисунок 1 – Реализация функции, формирующей строку из 500 чисел Фибоначчи

Реализуем алгоритмы поиска.

Примечание. Все функции находят все вхождения подстроки *substring* в строку *line* и возвращает количество таких вхождений – *cnt*. Переменные *m* и *n* в контексте данного задания всегда будут обозначать одно и то же – длину искомой подстроки и исходной строки соответственно.

➔ Реализуем наивный алгоритм поиска подстрок – за это будет отвечать функция *naive(line, substring)* (рис. 2)

Сам алгоритм наивного поиска подстроки заключается в том, что программа перебирает все возможные позиции, в которых может начинаться подстрока в строке и проверяет, совпадает ли подстрока с отрезком строки, начинающимся с текущей позиции. Для этого программа сначала определяет длину подстроки *substring* и строки *line*, а затем проходит циклом по позициям начала подстроки в строке (от *0* до *n - m*). Для каждой позиции программа проверяет соответствие символов подстроки и строки, начиная с текущей позиции. Если хотя бы один символ не совпадает, флаг *flag* устанавливается в 1 и производится выход из внутреннего цикла. Если после прохода по всем символам подстроки флаг *flag* остается равен 0, это означает, что найдено вхождение подстроки в строку, и счетчик *cnt* увеличивается на 1. По завершении всех

проверок, программа возвращает общее количество найденных вхождений подстроки в строку.

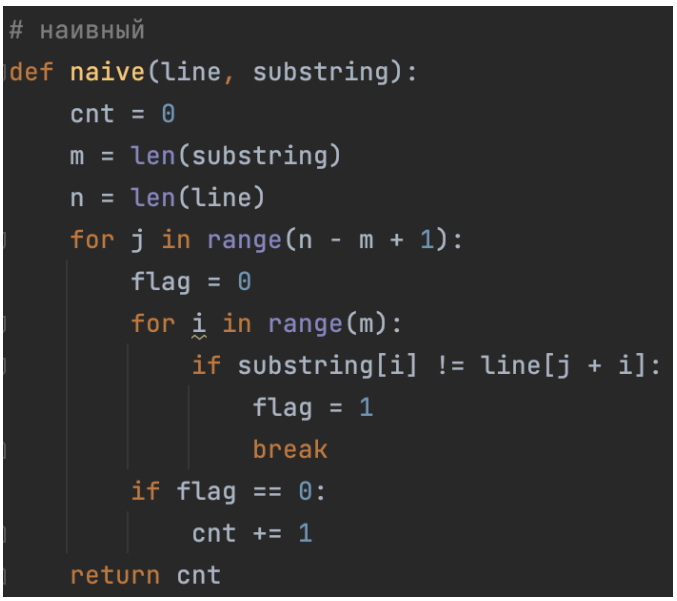

```
# наивный
def naive(line, substring):
    cnt = 0
    m = len(substring)
    n = len(line)
    for j in range(n - m + 1):
        flag = 0
        for i in range(m):
            if substring[i] != line[j + i]:
                flag = 1
                break
        if flag == 0:
            cnt += 1
    return cnt
```

Рисунок 2 – Реализация наивного алгоритма поиска подстроки в строке

➔ Реализуем алгоритм Рабина-Карпа – за это будут отвечать функции *r_k_own_hash(line, substring)* и *r_k(line, substring)* (рис. 3 и рис. 4)

Алгоритм Рабина-Карпа работает на основе хэширования – каждому символу в исходной строке присваивается числовое значение, которое затем используется для расчета хэша строк.

Попробуем рассчитать хэш самостоятельно. Сначала создадим словарь *numbers_for_symbols*, где ключами будут являться символы из исходной строки *line*, а значениями – соответствующие им числовые значения. Затем программа вычисляет хэш искомой подстроки *h_substring* с использованием числовых значений символов из словаря *numbers_for_symbols*. Далее программа вычисляет хэш *h_line_part* для каждой подстроки длиной *m* в строке *line*. Если хэши двух подстрок (искомой и текущей в строке) совпадают, выполняется посимвольное сравнение строк аналогично наивному алгоритму. Если символы в подстроках совпадают, увеличивается счетчик *cnt*, который в конце вычислений вернется в качестве результата данной функции - количества раз, которое подстрока встречается в исходной строке. Реализация программы представлена на рисунке 3.

При этом хэш можно вычислить с помощью встроенного метода *hash()*, тогда программа примет вид, изображенный на рисунке 4. Далее мы убедимся, что использование встроенной функции значительно ускоряет алгоритм.

```python
# Рабина-Карпа с самостоятельным подсчетом хэша
def r_k_own_hash(line, substring):
    n, m = len(line), len(substring)
    numbers_for_symbols = {}
    for i in range(n):
        if line[i] not in line[:i]:
            numbers_for_symbols[line[i]] = i
    cnt, h_substring, x = 0, 0, len(numbers_for_symbols)
    for k in range(m):
        h_substring += numbers_for_symbols[substring[k]] * x ** (m - 1 - k)
    h_line_part = 0
    for j in range(n - m + 1):
        line_part = line[j:j + m]
        if len(line_part) == m:
            if j == 0:
                for k in range(m):
                    h_line_part += numbers_for_symbols[line_part[k]] * x ** (m - 1 - k)
            else:
                h_line_part = (h_line_part - numbers_for_symbols[line[j - 1]] * x ** (m - 1)) * x \
                              + numbers_for_symbols[line_part[m - 1]]
            if h_substring == h_line_part:
                flag = 0
                for i in range(m):
                    if substring[i] != line[j + i]:
                        flag = 1
                        break
                if flag == 0:
                    cnt += 1
    return cnt
```

Рисунок 3 – Реализация алгоритма Рабина-Карпа поиска подстроки в строке (собственная реализация расчета хэша)

```python
# Рабина-Карпа
def r_k(line, substring):
    n, m = len(line), len(substring)
    cnt, h_substring = 0, hash(substring)
    for j in range(n - m + 1):
        line_part = line[j:j + m]
        if len(line_part) == m:
            h_line_part = hash(line_part)
            if h_substring == h_line_part:
                flag = 0
                for i in range(m):
                    if substring[i] != line[j + i]:
                        flag = 1
                        break
                if flag == 0:
                    cnt += 1
    return cnt
```

Рисунок 4 – Реализация алгоритма Рабина-Карпа поиска подстроки в строке (расчета хэш с помощью *hash()*)

➔ Реализуем алгоритм Бойера-Мура – за это будет отвечать функция *b_m(line, substring)* (рис. 5)

Для реализации алгоритма необходимо сформировать внутри функции таблицу смещений *d*, чтобы определить, на какую позицию нужно сместить поиск в случае несовпадения символов. Данная таблица обеспечивает более эффективный алгоритм поиска. Затем производится поиск подстроки в строке с помощью двух вложенных циклов. В первом цикле осуществляется проход по строке *line*, начиная с позиции *m-1*. Во втором цикле осуществляется сравнение символов подстроки с символами строки. В случае несовпадения символов подстроки и строки, вычисляется смещение *off* и совершается переход на новую позицию для сравнения символов. Если все символы подстроки совпадают с соответствующими символами строки, счетчик *cnt* увеличивается на 1, и продолжается поиск с новой позиции.

```
# Бойера-Мура
def b_m(line, substring):
    m = len(substring)
    d = {}
    for i in range(m - 2, -1, -1):
        if substring[i] not in d:
            d[substring[i]] = m - i - 1
    if substring[m - 1] not in d:
        d[substring[m - 1]] = m
    d['*'] = m
    cnt = 0
    n = len(line)
    i = m - 1
    while i < n:
        k = 0
        for j in range(m - 1, -1, -1):
            if line[i - k] != substring[j]:
                if j == m - 1:
                    off = d[line[i]] if d.get(line[i], False) else d['*']
                else:
                    off = d[substring[j]]
                i += off
                break
            k += 1
            if j == 0:
                cnt += 1
                i += 1
    return cnt
```

Рисунок 5 – Реализация алгоритма Бойера-Мура поиска подстроки в строке

➔ Реализуем алгоритм Кнута-Морриса-Пратта – за это будет отвечать функция *k_m_p(line, substring)* (рис. 6)

Сначала в функции создается список *pi*, хранящий значения префикс-функций строк (то есть длину максимального суффикса подстроки, который является одновременно и её префиксом). Это необходимо для оптимизации сравнения символов при поиске подстроки. Затем программа начинает перебирать символы строки *line* и подстроки *substring*, сравнивая их. Если символы совпадают, перебор продолжается дальше. Если символы не совпадают, программа использует таблицу *pi* для определения сдвига, который можно сделать без потери информации.

```python
# Кнута-Морриса-Пратта
def k_m_p(line, substring):
    m = len(substring)
    pi = []
    for i in range(1, m + 1):
        s = substring[:i]
        p = 0
        for j in range(1, i):
            if s[:j] == s[i - j:]:
                p = j
        pi.append(p)
    n = len(line)
    i, j, cnt = 0, 0, 0
    while i < n:
        if line[i] == substring[j]:
            i += 1
            j += 1
            if j == m:
                cnt += 1
                j = pi[j - 1]
        else:
            if j != 0:
                j = pi[j - 1]
            else:
                i += 1

    return cnt
```

Рисунок 6 – Реализация алгоритма Кнута-Морриса-Пратта поиска подстроки в строке

Используя каждый из этих алгоритмов, посчитаем количество наиболее часто встречающихся двузначных чисел в строке, состоящей из 500 чисел Фибоначчи. Параллельно измерим время, за которое происходит поиск.

```
Наивный 297 0.5004427433013916
Рабина-Карпа 297 0.4291951656341553
Рабина-Карпа (самостоятельный подсчет хэша) 297 1.773752212524414
Бойера-Мура 297 0.40508604049682617
Кнута-Морриса-Пратта 297 0.21019196510314941
```

Рисунок 7 – Количество наиболее часто встречающихся двузначных чисел в строке, подсчитанное различными алгоритмами, а также время выполнения алгоритмов

Видим, что для эффективной работы алгоритма Рабина-Карпа необходимо использовать встроенную функцию подсчета хэша.

Таблица 1. Сравнение алгоритмов поиска подстрок.

Название алгоритма	Достоинства	Недостатки
Наивный	- простота и понятность реализации.	- неэффективен; - медленно работает на больших текстах.
Рабина-Карпа	- эффективен на текстах с большим размером; - можно искать сразу несколько подстрок, заранее вычислив их хэш.	- возможность коллизий при вычислении хеш-функции, что может приводить к ложным совпадениям.
Бойера-Мура	- крайне эффективен на больших текстах за счет использования предварительной обработки подстроки.	- требует дополнительной памяти для хранения таблицы смещений.
Кнута-Морриса-Пратта	- эффективен на больших текстах; - эффективно обходит повторяющиеся символы	- требует предварительной обработки подстроки, что может быть неэффективно на коротких подстроках.

Задание 2

Задание: Дан набор рефератов. Выберите любой алгоритм поиска и определите количество плагиата (в % от общего количества символов в реферате) в тексте реферата, взяв за основу соответствующие статьи из Википедии (название файла = название статьи). За плагиат считать любые 3 совпавших слова, идущих подряд. Обоснуйте выбранный алгоритм поиска.

Решение:

Взят вариант 1 – файл «Логика.rtf».

Сначала переведем информацию из файла и страницы википедии в текстовые строки. Для перевода содержимого .rtf файла в текст пользуемся модулем *rtf_to_text* библиотеки *striprtf*. Для чтения содержимого страницы Википедии пользуемся модулем *wikipedia*. Далее удаляем из обеих строк ненужные символы, оставляя только буквы (так как будем смотреть только на совпавшие слова), приводим все буквы к одному регистру командой *lower()* и удаляем множественные пробелы строкой *text = ' '.join(text.split())*. Полный код программы представлен на рисунке 8.

```
import wikipedia
import re
import algorithms
from striprtf.striprtf import rtf_to_text


def rtf_read(rtf_file_path):
    with open(rtf_file_path, 'r') as rtf_file:
        return rtf_to_text(rtf_file.read())


# Открываем файл rtf
text = rtf_read('Логика.rtf')
text = re.sub(r'[^а-яА-Я\s]', ' ', text).lower()
text = ' '.join(text.split())

# Скачиваем статью из Википедии
wikipedia.set_lang("ru")
p = wikipedia.page('Логика')
Wiki_content = p.content
text_Wiki = re.sub(r'[^а-яА-Я\s]', ' ', Wiki_content).lower()
text_Wiki = ' '.join(text_Wiki.split())
```

Рисунок 8 – Формирование строк из .rtf файла и страницы Википедии

Далее посчитаем количество слов, которые можно считать плагиатом. Сохраним данное значение в переменную *plagiat*. Для поиска подстрок из Википедии в строке, содержащей текст реферата, воспользуемся методом поиска Бойера-Мура, так как он

обладает следующими преимуществами:

➔ Скорость работы: алгоритм Бойера-Мура является одним из самых быстрых алгоритмов поиска подстроки. Он работает эффективно даже при больших объемах текста;

➔ Эффективность поиска: данный алгоритм построен на таблице смещений, которая позволяет ему пропускать большие участки текста, если он уверен, что в них нет совпадения. В нашем случае, когда подстрока относительно большая, ведь она почти всегда содержит 3 объединенных слова, это сильно снижает количество сравнений и улучшает производительность.

Алгоритм Бойера-Мура импортируем из прошлого задания. Для определения количества плагиата в первую очередь, необходимо разделить исходный текст и текст из Википедии на слова. После этого проделывается поиск каждой тройки подряд расположенных слов из текста из Википедии внутри строки из набора слов исходного текста. В случае, если находится совпадение, оно записывается как плагиат, который прибавляется к переменной *plagiat*. Если мы нашли совпадение трех слов, то пробуем находить совпадения далее, формируя искомую строку уже из 4 и более слов. Во избежание ситуации повторного нахождения одной и той же подстроки инициируем переменную k – с помощью неё мы будем пропускать ненужные итерации i, для которых подстроки уже были найдены. В конце выводится количество плагиата в процентах относительно общего количества символов в реферате (то есть количество слов, идентифицированных как плагиат, деленное на общее количество слов).

```
words = [i for i in text.split(' ')]
words_Wiki = [i for i in text_Wiki.split(' ')]
plagiat = 0
flag = False
k = 0
for i in range(len(words_Wiki) - 2):
    if k != 0:
        k -= 1
        continue
    if not flag:
        substring = ' '.join(words_Wiki[i + j] for j in range(3))
        if algorithms.b_m(text, substring) != 0:
            plagiat += 3
            flag = True
    else:
        k = 1
        while flag:
            substring = ' '.join(words_Wiki[i + j] for j in range(3 + k))
            if algorithms.b_m(text, substring) != 0:
                plagiat += 1
            else:
                flag = False
            k += 1
print(f"Количество плагиата (в % от общего количества символов в реферате): {plagiat / len(words)}")
```

Рисунок 9 – Реализация программы для подсчета количества плагиата

```
Количество плагиата (в % от общего количества символов в реферате): 0.19129019129019129
```

Рисунок 10 – Вывод программы для файла «Логика.rtf»

ЗАКЛЮЧЕНИЕ

В ходе данной лабораторной работы были изучены и реализованы основные алгоритмы поиска подстрок – наивный, алгоритм Рабина-Карпа, Бойера-Мура и Кнута-Морриса-Пратта.

Была решена задача подсчета количества наиболее часто встречающихся двузначных чисел в строке, состоящей из 500 чисел Фибоначчи с использованием каждого из алгоритмов поиска подстрок. Самым медленным из примененных алгоритмов оказался наивный поиск, самым быстрым – алгоритм Кнута-Морриса-Пратта (время, затраченное на поиск подстроки наивным методом превысило время поиска подстроки методом Кнута-Морриса-Пратта примерно в 2.5 раза). Наивный алгоритм поиска подстрок, хоть и прост в реализации, имеет квадратичную сложность и неэффективен на больших объемах данных. Быстродействие алгоритма Рабина-Карпа сильно зависит от метода расчета хэша – при использовании встроенной функции *hash()* алгоритм сравним по времени с алгоритмом Бойера-Мура. Тогда время работы обоих алгоритмов является средним между наивным поиском и алгоритмом Кнута-Морриса-Пратта – они демонстрируют высокую эффективность при поиске подстроки в больших объемах данных. Можно сказать, что алгоритм Бойера-Мура имеет преимущество в том, что он позволяет совершать просмотры текста справа налево, что может сократить количество сравнений. Однако при самостоятельном вычислении хэша работа алгоритма Рабина-Карпа сильно замедляется.

При анализе плагиата в тексте реферата был выбран алгоритм Бойера-Мура в силу его высокой скорости работы, возможности эффективного обнаружения совпадений и умения пропускать большие участки текста, если он уверен, что в них нет совпадения. Он позволяет искать совпадения сразу в нескольких местах одновременно и сокращает время поиска.

Таким образом, в зависимости от ситуации можно выбрать подходящий алгоритм поиска подстрок для оптимальной работы с данными.

СПИСОК ЛИТЕРАТУРЫ

1) Wikipedia. Алгоритм Рабина-Карпа. [Электронный ресурс] – (Дата последнего обращения 19.05.2024);
2) Wikipedia. Алгоритм Бойера-Мура. [Электронный ресурс] – (Дата последнего обращения 19.05.2024);
3) Wikipedia. Алгоритм Кнута-Морриса-Пратта [Электронный ресурс] – (Дата последнего обращения 19.05.2024).

ПРИЛОЖЕНИЕ

Для удобства все файлы выгружены на GitHub: https://github.com/kathykkKk/Algorithms-and-Data-Structures-ICT.git